

Workflows Dinâmicos em IA: Agentes, Subagentes e o Papel da Orquestração

OpenClaw Agency

12 de julho de 2026

1 Dynamic Workflows com AI Agents e Sub-Agents: Padrões de Orquestração e Frameworks para Produção

[AUTOR]^{1*}

¹ [AFILIAÇÃO DO AUTOR — DEPARTAMENTO, INSTITUIÇÃO, CIDADE, PAÍS]

Autor correspondente: [EMAIL]

1.1 Resumo

A adoção de sistemas multi-agente evoluiu de experimentos de laboratório para implantações empresariais em escala entre 2024 e 2026, impulsionada pela maturidade dos modelos de linguagem de grande porte (LLMs). O presente artigo apresenta uma síntese crítica e uma análise arquitetônica dos padrões fundamentais de orquestração de agentes de inteligência artificial (AI Agents) e sub-agentes (Sub-Agents) em ambientes de produção. Discute-se, detalhadamente, seis padrões de orquestração — Orchestrator-Worker (Supervisor), Sequential Pipeline, Parallel Fan-Out/Fan-In, Dynamic Handoff (Routing), Group Chat e Magentic (Planning-Ledger) — bem como os três padrões de interação de sub-agentes (síncrono, assíncrono e agendado) e o papel central da compressão de contexto. Adicionalmente, analisa-se a maturidade, os diferenciais e a adequação dos principais frameworks do ecossistema — LangGraph, CrewAI, OpenAI Agents SDK, Claude Agent SDK, Microsoft Agent Framework e Spring AI Agent Utils — por meio de uma matriz de compatibilidade estruturada e de uma matriz de critérios de seleção. O texto examina, ainda, aplicações setoriais documentadas, a modelagem quantitativa de custos e latência, os riscos e limitações da abordagem e um roteiro de adoção em produção. O artigo conclui com diretrizes práticas de engenharia para adoção em produção, abrangendo gerenciamento de contexto, otimização de custos, segurança orientada ao princípio do menor privilégio, human-in-the-loop e observabilidade.

Palavras-chave: Agentes de IA. Workflows Dinâmicos. Orquestração Multi-agente. Padrões de Arquitetura. LangGraph. CrewAI.

1.2 Abstract

The adoption of multi-agent systems has evolved from laboratory experiments to enterprise-scale production deployments between 2024 and 2026, driven by the maturity of large language models (LLMs). This article presents a critical synthesis and an architectural analysis of the fundamental orchestration patterns for artificial intelligence agents (AI Agents)

and sub-agents (Sub-Agents) in production environments. Six orchestration patterns are discussed in detail — Orchestrator-Worker (Supervisor), Sequential Pipeline, Parallel Fan-Out/Fan-In, Dynamic Handoff (Routing), Group Chat, and Magentic (Planning-Ledger) — along with the three sub-agent interaction patterns (synchronous, asynchronous, and scheduled) and the central role of context compression. Furthermore, the maturity, differentials, and suitability of the main ecosystem frameworks — LangGraph, CrewAI, OpenAI Agents SDK, Claude Agent SDK, Microsoft Agent Framework, and Spring AI Agent Utils — are analyzed through a structured compatibility matrix and a selection-criteria matrix. The text also examines documented sector applications, the quantitative modeling of cost and latency, the risks and limitations of the approach, and a production adoption roadmap. The article concludes with practical engineering guidelines for production adoption, covering context management, cost optimization, security oriented to the principle of least privilege, human-in-the-loop, and observability.

Keywords: AI Agents. Dynamic Workflows. Multi-agent Orchestration. Architectural Patterns. LangGraph. CrewAI.

1.3 1. Introdução

A inteligência artificial generativa atingiu maturidade em que LLMs resolvem tarefas isoladas com alta competência. Problemas complexos do mundo real, porém, raramente são estanques: um processo empresarial típico envolve pesquisa, análise, redação, revisão, aprovação e publicação, cada etapa com habilidades e critérios distintos (VELLUM AI, 2025). Um modelo generalista tende a resultados medianos ao manter todo o contexto enquanto se especializa em cada subtarefa.

Daí emergem os sistemas multi-agente: múltiplos agentes especializados colaboram, cada um com seu modelo, ferramentas e instruções (MICROSOFT, 2026), tornando o sistema modular, auditável e resiliente, e reduzindo regressões em cascata. O valor central dos sub-agentes não é só paralelismo, mas compressão de contexto: bem projetados, mantêm o contexto do pai enxuto, reduzindo tokens em mais de 90% e prevenindo degradação por limite de contexto (EPSILLA, 2026).

O objetivo deste artigo é oferecer uma referência arquitetônica consolidada, mapeando padrões, mecanismos de sub-agentes, frameworks e diretrizes de engenharia para produção.

1.4 2. Fundamentos de Dynamic Workflows

Dynamic Workflows são arquiteturas nas quais múltiplos agentes colaboram de forma coordenada (ZYLOS RESEARCH, 2026). Diferente de pipelines estáticos, a topologia — quais agentes, em que ordem e frequência — é definida em tempo de execução, conforme o contexto e resultados parciais. A distinção estático/dinâmico é sobre *onde* a decisão de controle reside: em design ou delegada ao modelo.

O conceito apoia-se em três pilares (MICROSOFT, 2026; AWS, 2025): **Decomposição** (tarefa em subtarefas especializáveis); **Delegação** (à unidade mais qualificada por especialização, custo e segurança); **Coordenação** (agregação e integração dos resultados). A orquestração pode ser estática (topologia em design) ou dinâmica (emerge por decisões de LLMs); a maioria adota híbrido: estrutura predefinida para consistência, com roteamento e replanejamento dinâmicos (AWS, 2025).




Figura 1: Figura 1. Esquema comparativo das topologias estática, dinâmica e híbrida de orquestração multi-agente, ilustrando o locus da decisão de controle.

1.5 3. Padrões de Orquestração em Produção

O ecossistema contemporâneo de engenharia de software voltado à inteligência artificial converge para seis padrões fundamentais de orquestração de agentes (MICROSOFT, 2026; ZYLOS RESEARCH, 2026). A seleção do padrão adequado deve considerar o grau de acoplamento entre as etapas, a necessidade de consenso entre especialistas e a tolerância a latência. A Tabela 1 sintetiza, ao final da seção, os trade-offs de cada padrão.

1.5.1 3.1 Orchestrator-Worker (Supervisor)

O padrão Orchestrator-Worker, frequentemente denominado Supervisor, é a arquitetura mais difundida em sistemas multi-agente comerciais. Um agente orquestrador central recebe a requisição do usuário, decompõe o problema em subtarefas, delega cada subtarefa a um agente especialista (*worker*), monitora o progresso de execução e sintetiza o resultado final (MICROSOFT, 2026). O orquestrador mantém o estado global e a responsabilidade pela consistência do produto entregue.

Este padrão é indicado para workflows complexos onde a decomposição requer julgamento contextual e os planos variam conforme a entrada. Por outro lado, adiciona 15% a 30% de latência e consome 20% a 40% mais tokens devido às idas e voltas com os *workers* (MICROSOFT, 2026). A centralização também introduz gargalo: a capacidade do orquestrador limita o *throughput*.

O Claude Agent SDK da Anthropic implementa este padrão como primitiva fundamental por meio da capacidade de expor agentes como ferramentas programáticas utilizando ‘agent.asTool()’ (ANTHROPIC, 2026a). A Microsoft, por sua vez, adota a mesma estrutura mapeando os agentes em grafos de fluxo de trabalho com transições explícitas (MICROSOFT, 2026). A escolha entre implementação via ferramentas programáticas (Anthropic) e via grafos explícitos (Microsoft) reflete um trade-off entre flexibilidade de composição e previsibilidade de execução.

1.5.2 3.2 Sequential Pipeline (Prompt Chaining)

Agentes encadeados em ordem linear estrita; a saída de um serve de entrada ao próximo (AWS, 2025; DEVARAJAN, 2026). Recomenda-se para dependências lineares claras (geração → revisão → verificação → formatação); evitar quando há *backtracking* (LUSHBINARY,

2026).

1.5.3 3.3 Parallel Fan-Out / Fan-In

Execução simultânea de múltiplos agentes por especialidade; consolidação em nó de agregação por votação ou sumarização (DIGITAL APPLIED, 2026). Ideal para análise multi-perspectiva sob restrição de tempo (PUCEK, 2026).

1.5.4 3.4 Dynamic Handoff (Routing)

Agentes decidem autonomamente quando transferir o controle a outro especialista; a transferência é definitiva, operando um agente por vez (OPENAI, 2026; MICROSOFT, 2026). Aplicável em triagem de atendimento; OpenAI expõe ‘handoff()’ (OPENAI, 2026), Claude via sub-agentes isolados (ANTHROPIC, 2026a).

1.5.5 3.5 Group Chat (Roundtable)

Múltiplos agentes em *thread* compartilhado; um *chat manager* define quem fala a cada turno, permitindo consenso (MICROSOFT, 2026). Rico em cruzamento de perspectivas, custa latência e difícil término (SUBAGENT.DEV, 2026).

1.5.6 3.6 Magentic (Planning-Ledger)

Para escopo aberto: o agente mantém um *ledger* dinâmico de tarefas, reavaliando e acionando sub-agentes conforme o contexto evolui (MICROSOFT, 2026). Usado em SRE e resposta a incidentes (ZYLOS RESEARCH, 2026).

Tabela 1. Síntese comparativa dos seis padrões de orquestração quanto a latência, consumo de tokens, adequação a consenso e previsibilidade.

Padrão	Latência	Tokens	Consenso	Previsibilidade	Indicado para
Orchestrator-Worker	Alta	Alta	Média	Alta	Decomposição com j
Sequential Pipeline	Baixa	Baixa	Baixa	Muito alta	Dependências lineares
Parallel Fan-Out/Fan-In	Baixa	Alta	Alta	Média	Análise multi-perspec
Dynamic Handoff	Média	Média	Baixa	Média	Triagem e especializa
Group Chat	Alta	Alta	Alta	Baixa	Debate e design colab
Magentic	Alta	Alta	Média	Baixa	Escopo aberto, incide

Fonte: elaborado pelo autor com base em Microsoft (2026), OpenAI (2026), Zylos Research (2026), Epsilla (2026) e Digital Applied (2026).

1.6 4. Sub-Agents: Padrões de Interação e Compressão de Contexto

Além dos padrões de orquestração de alto nível, a operação eficiente de sub-agentes em produção depende de três categorias operacionais de interação (EPSILLA, 2026):

Synchronous "Wait and See": o agente pai suspende sua execução e aguarda o retorno do sub-agente, comportando-se de forma análoga a uma chamada de função complexa. É o modo mais simples de raciocinar e depurar, porém limita o paralelismo do sistema. **Asynchronous "Fire and Forget":** o agente pai delega

uma tarefa e continua seu fluxo de execução em paralelo, útil para processamento assíncrono ou disparos de eventos. Exige mecanismos de correlação para consumir o resultado posteriormente. **Scheduled "Future Execution"**: o sub-agente é programado para executar em um momento futuro predeterminado ou sob gatilhos temporais específicos. É a base da automação orientada a eventos e da execução recorrente.

O insight central desse desacoplamento não reside apenas no processamento paralelo, mas na compressão do contexto de inferência. Ao isolar sub-tarefas em sub-agentes dotados de escopos de variáveis e ferramentas restritas, reduz-se o volume total de tokens acumulados nas janelas de contexto dos modelos principais, prevenindo a degradação da acurácia causada pelo fenômeno de "esquecimento no meio do contexto" (*lost in the middle*) (EPSILLA, 2026; VELLUM AI, 2025). O agente pai recebe apenas o resultado sintetizado da investigação, e não o rastro completo das ferramentas acionadas — o que explica a redução documentada de mais de 90% no consumo de tokens (EPSILLA, 2026).

A compressão de contexto opera em duas dimensões: (i) *temporal*, ao descartar ou resumir histórico obsoleto; e (ii) *espacial*, ao delimitar o escopo de ferramentas e variáveis de cada sub-agente. A combinação das duas torna viável a execução de tarefas de longa duração sem estouro da janela de contexto.




Figura 2: Figura 2. Representação do fluxo de compressão de contexto: o rastro detalhado das ferramentas permanece no sub-agente, enquanto o agente pai recebe apenas o resultado resumido.

1.7 5. Ecossistema de Frameworks e Ferramentas

O mercado de ferramentas para orquestração de agentes registrou rápida consolidação em torno de frameworks especializados (GHEWARE, 2026; JETTHOUGHTS, 2026). A escolha do framework não é meramente técnica: ela determina o modelo mental dos desenvolvedores, os limites de segurança disponíveis e a facilidade de observabilidade. A seguir, analisam-se os seis principais frameworks do ecossistema.

1.7.1 5.1 LangGraph

Extensão do LangChain para fluxos cíclicos modelados como grafos de estado, com controle preciso de execução (AGENT MARKET CAP, 2026). Diferenciais: *checkpointing*, *time-travel debugging*, integração LangSmith; limitação: curva íngreme (OPENAGENTS, 2026).

1.7.2 5.2 CrewAI

Metáfora organizacional de *crews* com papéis e memórias predefinidos (META INTELLIGENCE, 2025). Diferenciais: prototipagem rápida; limitação: controle granular limitado para dinâmicos (GHEWARE, 2026).

1.7.3 5.3 OpenAI Agents SDK

Foco em ‘handoffs’ simplificados, guardrails declarativos e *tracing* (OPENAI, 2026).

1.7.4 5.4 Claude Agent SDK

Foco em MCP e execução integrada a IDEs, com o *harness* do Claude Code, sub-agentes isolados e paralelização nativa (ANTHROPIC, 2026b; WINBUZZER, 2026).

1.7.5 5.5 Microsoft Agent Framework

Sucessor corporativo do AutoGen, integrado ao Azure, com *workflow graphs* e ênfase em conformidade (ROCKB, 2026).

1.7.6 5.6 Spring AI Agent Utils

Voltado ao ecossistema Java/Spring Boot, com *Task tools* para isolamento, *multi-model routing* e A2A (TZOLOV, 2026).

1.7.7 5.7 Matriz de Compatibilidade de Frameworks

A Tabela 2 apresenta a avaliação de compatibilidade nativa entre os frameworks analisados e os padrões de orquestração discutidos, consolidada a partir da literatura técnica revisada.

Tabela 2. Matriz de compatibilidade entre frameworks e padrões de orquestração

Framework	Orchestrator	Sequential	Parallel	Handoff	Group
LangGraph	Nativo	Nativo	Nativo	Via nós	Via
CrewAI	Hierárquico	Nativo	Nativo	Limitado	Não s
OpenAI Agents SDK	Agent-as-Tool	Manual	Via <i>handoffs</i>	Nativo	Não s
Claude Agent SDK	Agent tool	Programático	Sub-agentes	Sub-agentes	Agen
MS Agent Framework	<i>Workflow graphs</i>	<i>Workflow graphs</i>	Nativo	Nativo	GroupC
Spring AI Agent Utils	<i>Task tool</i>	Programático	<i>Task tool</i>	<i>Task tool</i>	Não s

Fonte: adaptado de Microsoft (2026), OpenAI (2026), Anthropic (2026a, 2026b), Tzolov (2026), RockB (2026) e Zylos Research (2026).

1.7.8 5.8 Critérios de Seleção de Framework

A Tabela 3 propõe um critério estruturado de seleção, útil para arquitetos que enfrentam a decisão de adoção. Cada critério deve ser ponderado pelos requisitos do projeto.

Tabela 3. Matriz de critérios para seleção de framework

Critério	Peso sugerido	LangGraph	CrewAI	OpenAI SDK	Claude SD
Controle de estado	Alto				
Ergonomia/Prototipação	Médio				
Segurança/Conformidade	Alto				
Observabilidade	Alto				
Ecossistema/Integração	Médio				

Legenda: forte; moderado; limitado. Fonte: elaborado pelo autor com base em Agent Market Cap (2026), OpenAgents (2026), Gheware (2026), RockB (2026) e Shakudo (2026).

1.8 6. Aplicações Setoriais e Estudos de Caso

A adoção de *dynamic workflows* não é meramente teórica: casos de produção documentados ilustram a aplicabilidade dos padrões apresentados em domínios diversos. A análise desses casos permite extrair princípios de design transferíveis.

No setor jurídico, um escritório utiliza um pipeline sequencial de quatro agentes para geração de contratos — seleção de template, customização de cláusulas, verificação de *compliance* e avaliação de risco (SHAKUDO, 2025) — refletindo a natureza regulatória e a necessidade de determinismo.

No financeiro, a análise de investimentos emprega Parallel Fan-Out/Fan-In, com agentes em paralelo para análises fundamentalista, técnica, de sentimento e ESG, convergindo para um relatório consolidado (PUCEK, 2026). No atendimento ao cliente, o Dynamic Handoff usa um agente de triagem que transfere para especialistas em suporte, faturamento ou retenção (OPENAI, 2026), otimizando contexto por especialista.

Na SRE, o padrão Magentic sustenta a resposta a incidentes, onde o agente analisa logs, delega diagnósticos e aplica correções à medida que o sistema se revela (ZYLOS RESEARCH, 2026). Em produção de conteúdo técnico, o Orchestrator-Worker coordena rascunho, revisão, verificação de fatos e formatação (VELLUM AI, 2025), demonstrando como a decomposição com julgamento contextual supera a execução monolítica.




Figura 3: Mapa de alinhamento entre padrões de orquestração e domínios de aplicação setorial.

1.9 7. Modelagem de Custos e Latência

A viabilidade econômica depende de modelagem cuidadosa, pois a orquestração introduz overhead sobre a execução mono-agente. O padrão Orchestrator-Worker adiciona 15%–30% de latência e 20%–40% de tokens (MICROSOFT, 2026); tais números devem ser confrontados com os ganhos de qualidade e de compressão antes da adoção.

Em contrapartida, a compressão por sub-agentes reduz o consumo do agente pai em mais de 90% (EPSILLA, 2026), superando o overhead em tarefas longas. A arquitetura de custos deve seguir *difficulty-aware routing*: modelos menores para roteamento e verificações; avançados reservados a planejamento e consolidação (GROKIPEDIA, 2026). A Tabela 4 ilustra o efeito combinado. Recomenda-se compactar quando o contexto excede 70% do limite (STACKVIV, 2026).

Tabela 4. Efeito qualitativo de decisões de arquitetura sobre custo e latência

Decisão de arquitetura	Efeito em custo	Efeito em latência	Fonte
Sub-agentes com compressão de contexto	Reduz	Neutro/Positivo	Epsilla (2026)
Orchestrator-Worker	Aumenta	Aumenta	Microsoft (2026)
Parallel Fan-Out	Aumenta	Reduz	Digital Applied
Difficulty-aware routing	Reduz	Neutro	Grokikipedia (2026)
Checkpointing/pruning a 70%	Reduz	Neutro	Stackviv (2026)

Fonte: elaborado pelo autor com base nas referências citadas.

1.10 8. Diretrizes de Engenharia para Produção

A transição de protótipos de agentes para sistemas multi-agente de produção estável exige a aplicação de rigorosas diretrizes de engenharia (WITNESSAI, 2026; STACKVIV, 2026). As subseções a seguir detalham os cinco eixos centrais.

1.10.1 8.1 Gerenciamento Dinâmico de Contexto

À medida que múltiplos agentes interagem, a janela de contexto satura rapidamente. Sistemas em produção devem implementar sumarização incremental e *pruning* — remoção de metadados irrelevantes e respostas intermediárias de ferramentas. Recomenda-se compactar quando o contexto excede 70% do limite (STACKVIV, 2026), preservando artefatos de decisão e descartando o rastro de ferramentas de baixo valor.

1.10.2 8.2 Otimização de Custos e Latência

A arquitetura de custos deve seguir *difficulty-aware routing*: modelos menores para roteamento e verificações; avançados reservados a planejamento e consolidação (GROKIPEDIA, 2026). *Caching* de contexto e reutilização de sub-resultados reduzem o custo marginal de requisições repetitivas.

1.10.3 8.3 Segurança e Isolamento

Sub-agentes devem operar sob o menor privilégio, restringindo acesso a APIs e dados ao escopo da tarefa. *Circuit breakers* e cotas rígidas previnem loops infinitos (WITNESSAI, 2026). O isolamento de contexto (Claude Agent SDK, ANTHROPIC, 2026b) limita o raio de explosão de um comprometimento.

1.10.4 8.4 Human-in-the-Loop

Padrões suportam participação humana: observadores em *group chat*, revisores *maker-checker* e escalção em *handoff*. Pontos de verificação obrigatórios tornam a orquestração síncrona e o estado é persistido para retomada sem *replay* (MICROSOFT LEARN, 2026), recomendável em domínios de alto risco.

1.10.5 8.5 Observabilidade

O *stack* mínimo combina LangSmith (rastreamento), OpenTelemetry (métricas) e *dashboards* de *workflow engine*, instrumentando toda operação e todo *handoff* (SHAKUDO, 2026; APISCOUT, 2026). Sem observabilidade, a depuração de topologias dinâmicas torna-se inviável dado o não determinismo de roteamento.

1.11 9. Riscos, Limitações e Estratégias de Mitigação

Apesar dos ganhos, a adoção de *dynamic workflows* introduz riscos que devem ser explicitamente geridos. Esta seção cataloga as limitações documentadas e propõe mitigações alinhadas às diretrizes da Seção 8.

Não determinismo de roteamento. LLMs em tempo de execução podem divergir entre execuções equivalentes. *Mitigação:* abordagem híbrida com estrutura predefinida e limites explícitos (AWS, 2025); persistir traços para auditoria (SHAKUDO, 2026; APISCOUT, 2026).

Custo de tokens da orquestração. Overhead de 20%–40% em tokens e 15%–30% em latência (MICROSOFT, 2026) inviabiliza alto volume. *Mitigação:* *difficulty-aware routing* (GROKIPEDIA, 2026) e compressão (EPSILLA, 2026).

Depuração de topologias dinâmicas. Múltiplos caminhos dificultam a causa raiz. *Mitigação:* observabilidade integral (SHAKUDO, 2026; APISCOUT, 2026) e *time-travel debugging* (AGENT MARKET CAP, 2026).

Segurança e loops. Sub-agentes com privilégios excessivos e sem *circuit breaker* induzem loops ou exfiltração. *Mitigação:* menor privilégio e cotas rígidas (WITNESSAI, 2026).

Interoperabilidade. Fragmentação de protocolos (A2A, MCP) limita portabilidade. *Mitigação:* preferir frameworks com suporte nativo aos protocolos emergentemente padronizados (TZOLOV, 2026; MICROSOFT, 2026).

1.12 10. Tendências Emergentes

Seis tendências moldam o futuro (ZYLOS RESEARCH, 2026; MICROSOFT LEARN, 2026): (1) **DAGs** como linguagem de especificação (LangGraph); (2) **Orquestração *Event-Driven*** sobre barramentos (Kafka, RabbitMQ); (3) **Modelo *Actor*** (AutoGen, MAF); (4) **Roteamento Dinâmico por Dificuldade**; (5) **Orquestração Federada *cloud-edge*** via A2A; (6) **Workflows Auto-Otimizáveis** por meta-agentes. A adoção antecipada de A2A/MCP evita *lock-in* e habilita orquestração federada e auto-otimizável.

1.13 11. Roadmap de Adoção em Produção

A partir das diretrizes e riscos discutidos, propõe-se um roteiro de adoção em três fases, desenhado para minimizar risco enquanto se constrói competência organizacional.

Fase 1 — Fundação (1–4 sem.). *Stack* de observabilidade (LangSmith, OpenTelemetry) e modelo de isolamento de contexto e privilégios (WITNESSAI, 2026; SHAKUDO, 2026); iniciar com agentes generalistas simples.

Fase 2 — Orquestração Híbrida (5–10 sem.). Orchestrator-Worker ou Sequential Pipeline conforme a tarefa, com compressão por sub-agentes (EPSILLA, 2026) e *difficulty-aware routing* (GROKIPEDIA, 2026); persistir *checkpoints* (MICROSOFT LEARN, 2026).

Fase 3 — Escala e Autonomia (11+ sem.). Parallel Fan-Out/Fan-In e Dynamic Handoff para análise multi-perspectiva; *human-in-the-loop* em pontos críticos; Magentic para escopo aberto (ZYLOS RESEARCH, 2026); reavaliar topologia por custo/latência (Tabela 4).

A recomendação central é evoluir de topologias estáticas para dinâmicas de forma incremental, sustentada por observabilidade desde o primeiro dia.

1.14 12. Conclusão

Os padrões de orquestração multi-agente evoluíram de conceitos acadêmicos para pilares de arquitetura em produção empresarial. A escolha do padrão e do framework deve ser guiada por requisitos pragmáticos de latência, custos e complexidade, não por preferências de implementação. A compressão de contexto por sub-agentes consolida-se como o principal benefício prático, com reduções documentadas de mais de 90% em tokens do agente pai (EPSILLA, 2026).

Recomenda-se uma arquitetura híbrida em camadas — durabilidade (Temporal), raciocínio de agente (LangGraph), coordenação inter-serviço (Kafka + A2A) e observabilidade desde o primeiro dia — evoluindo de topologias estáticas para dinâmicas de forma incremental. Limitações atuais incluem a depuração de topologias dinâmicas, o custo de tokens da orquestração e a padronização de protocolos (A2A, MCP). Perspectivas futuras apontam para DAGs como linguagem de especificação, orquestração orientada a eventos e workflows auto-otimizáveis. O sucesso dependerá da disciplina de engenharia em observabilidade, segurança por menor privilégio e *human-in-the-loop* em pontos de alto risco.

1.15 Agradecimentos

[Os autores agradecem — A PREENCHER conforme política institucional e fontes de financiamento]

1.16 Referências

AGENT MARKET CAP. LangGraph vs AutoGen vs CrewAI vs DSPy: The 2026 Multi-Agent Framework Decision Guide. **Agent Market Cap**, 2026. Disponível em: <https://agent-marketcap.ai/blog/2026/04/11/langgraph-autogen-crewai-dspy-multi-agent-orchestration-2026>. Acesso em: 12 jul. 2026.

ANTHROPIC. **Claude Agent SDK**: Subagents in the SDK. São Francisco: Anthropic, 2026a. Disponível em: <https://code.claude.com/docs/en/agent-sdk/subagents>. Acesso em: 12 jul. 2026.

ANTHROPIC. **Claude Code**: Orchestrate subagents at scale with dynamic workflows. São Francisco: Anthropic, 2026b. Disponível em: <https://code.claude.com/docs/en/workflows>. Acesso em: 12 jul. 2026.

APISCOUT. **OpenAI Agents SDK**: Architecture Patterns 2026. APIScout, 2026. Disponível em: <https://apiscout.dev/guides/openai-agents-sdk-architecture-patterns-2026>.

Acesso em: 12 jul. 2026.

AWS. **Agentic AI patterns and workflows on AWS**. Seattle: Amazon Web Services, 2025. Disponível em: <https://docs.aws.amazon.com/prescriptive-guidance/latest/agentic-ai-patterns/introduction.html>. Acesso em: 12 jul. 2026.

DEVARAJAN, Vishalini. **Common Workflow Patterns for AI Agents**. GUVI Blog, 2026. Disponível em: <https://www.guvi.in/blog/common-workflow-patterns-for-ai-agents>. Acesso em: 12 jul. 2026.

DIGITAL APPLIED. **Multi-Agent Orchestration: 5 Patterns That Work in 2026**. Digital Applied, 2026. Disponível em: <https://www.digitalapplied.com/blog/multi-agent-orchestration-5-patterns-that-work>. Acesso em: 12 jul. 2026.

EPSILLA. **The 3 Essential Sub-Agent Patterns for Production-Grade AI Systems**. Epsilla Blog, 2026. Disponível em: <https://www.epsilla.com/blogs/2026-03-14-ai-sub-agent-patterns>. Acesso em: 12 jul. 2026.

GARTNER. **Market Guide for AI Agent Orchestration**. Stamford: Gartner, 2025. [VERIFICAR: relatório original e percentual exato de crescimento de consultas]

GHEWARE, Rajesh. **LangGraph vs CrewAI vs AutoGen: Complete AI Agent Framework Comparison 2026**. DevOps Gheware, 2026. Disponível em: <https://devops.gheware.com/blog/po-vs-crewai-vs-autogen-comparison-2026.html>. Acesso em: 12 jul. 2026.

GROKIPEDIA. **AI Agent Orchestration**. Grokipedia, 2026. Disponível em: https://grokipedia.com/page/AI_Agent_Orchestration. Acesso em: 12 jul. 2026.

JETTHOUGHTS. **LangGraph vs CrewAI vs AutoGen: Open Source Alternatives 2025**. JetThoughts, 2026. Disponível em: <https://jetthoughts.com/blog/autogen-crewai-langgraph-ai-agent-frameworks-2025>. Acesso em: 12 jul. 2026.

LUSHBINARY. **Multi-Agent AI Orchestration Patterns: Supervisor, Swarm, Pipeline & Router**. Lushbinary, 2026. Disponível em: <https://lushbinary.com/blog/multi-agent-orchestration-patterns-supervisor-swarm-pipeline-router-guide>. Acesso em: 12 jul. 2026.

META INTELLIGENCE. **LangGraph vs CrewAI vs AutoGen: AI Agent Framework Comparison [2026]**. Meta Intelligence, 2025. Disponível em: <https://www.meta-intelligence.tech/en/insight-ai-agent-frameworks>. Acesso em: 12 jul. 2026.

MICROSOFT. **AI Agent Orchestration Patterns**. Redmond: Azure Architecture Center, 2026. Disponível em: <https://learn.microsoft.com/en-us/azure/architecture/ai-ml/guide/ai-agent-design-patterns>. Acesso em: 12 jul. 2026.

MICROSOFT LEARN. **Multi-agent patterns**. Microsoft Learn, 2026. Disponível em: <https://learn.microsoft.com/en-us/agents/architecture/multi-agent-patterns>. Acesso em: 12 jul. 2026.

OPENAI. **Agents SDK: Orchestration and handoffs**. São Francisco: OpenAI, 2026. Disponível em: <https://developers.openai.com/api/docs/guides/agents/orchestration>. Acesso em: 12 jul. 2026.

OPENAGENTS. **CrewAI vs LangGraph vs AutoGen vs OpenAgents: Best AI Agent Framework**. OpenAgents, 2026. Disponível em: <https://openagents.org/blog/posts/2026-02-23-open-source-ai-agent-frameworks-compared>. Acesso em: 12 jul. 2026.

PUCEK, Bartek. **Orchestration Patterns for AI Agent Workflows**. The Thinking Company, 2026. Disponível em: <https://thinking.inc/en/blue-ocean/agentic/agent-orchestration-patterns>. Acesso em: 12 jul. 2026.

ROCKB. **Microsoft Agent Framework 2026: AutoGen Successor Explained**. RockB, 2026. Disponível em: <https://baeseokjae.github.io/posts/microsoft-agent-framework-2026/>. Acesso em: 12 jul. 2026.

SHAKUDO. **Enterprise Agentic AI Workflow Patterns for 2025**. Shakudo, 2025.

Disponível em: <https://cdn.prod.website-files.com/625447c67b621ab49bb7e3e5/69388ca4cdb5836ee83b1ai-workflow-patterns-whitepaper.pdf>. Acesso em: 12 jul. 2026.

SHAKUDO. **Multi-Agent Systems Transform Enterprise AI in 2026**. Shakudo, 2026. Disponível em: <https://cdn.prod.website-files.com/625447c67b621ab49bb7e3e5/696fdd9dcee4a9c1agent-systems-2026-trends-whitepaper.pdf>. Acesso em: 12 jul. 2026.

STACKVIV. **Agentic AI & Multi-Agent Systems: Advanced Guide**. Stackvivi, 2026. Disponível em: <https://stackviv.ai/blog/agentic-ai-multi-agent-systems-guide>. Acesso em: 12 jul. 2026.

SUBAGENT.DEV. **Orchestration Patterns**. SubAgent.Dev, 2026. Disponível em: <https://subagent.developersdigest.tech/patterns>. Acesso em: 12 jul. 2026.

TZOLOV, Christian. **Spring AI Agentic Patterns (Part 4): Subagent Orchestration**. Spring Blog, 2026. Disponível em: <https://spring.io/blog/2026/01/27/spring-ai-agentic-patterns-4-task-subagents/>. Acesso em: 12 jul. 2026.

VELLUM AI. **The 2026 Guide to AI Agent Workflows**. Vellum AI, 2025. Disponível em: <https://www.vellum.ai/blog/agentic-workflows-emerging-architectures-and-design-patterns>. Acesso em: 12 jul. 2026.

WINBUZZER. **Anthropic Shows How to Scale Claude Code with Subagents and MCP**. WinBuzzer, 2026. Disponível em: <https://winbuzzer.com/2026/03/24/anthropic-claude-code-subagent-mcp-advanced-patterns-xcxwbn>. Acesso em: 12 jul. 2026.

WITNESSAI. **AI Agent Orchestration: Managing Multi-Agent Workflows**. WitnessAI, 2026. Disponível em: <https://witness.ai/blog/ai-agent-orchestration>. Acesso em: 12 jul. 2026.

ZYLOS RESEARCH. **Agent Workflow Orchestration Patterns: DAG, Event-Driven, and Actor Models**. Zylos Research, 2026. Disponível em: <https://zylos.ai/research/2026-04-14-agent-workflow-orchestration-patterns>. Acesso em: 12 jul. 2026.