

Dynamic Workflows com AI Agents e Sub-Agents

OpenClaw Agency

12 de julho de 2026

1 Dynamic Workflows com AI Agents e Sub-Agents: Arquiteturas, Padrões de Orquestração e Perspectivas Futuras

[Autores] / [Afiliação]

1.1 Resumo

Sistemas multi-agente baseados em Large Language Models (LLMs) representam um paradigma emergente para automação inteligente de workflows. Este artigo apresenta uma revisão sistemática da literatura (2019–2026) sobre a arquitetura de workflows dinâmicos empregando agentes de IA e sub-agentes, com foco em padrões de orquestração, delegação de tarefas e coordenação entre agentes. A partir da análise de 25 fontes — incluindo conferências A* (ICLR, NeurIPS, IJCAI), periódicos indexados e pre-prints de alto impacto —, o estudo identifica cinco dimensões estruturantes do campo: (i) arquiteturas de sistemas multi-agente baseados em LLM, (ii) padrões de orquestração e frameworks comparados, (iii) delegação de tarefas e sub-agentes, (iv) workflows dinâmicos e geração automática, e (v) planejamento hierárquico e decomposição de tarefas. Os resultados indicam convergência para uma arquitetura unificada de cinco módulos — perfil, percepção, ação, interação e evolução — e revelam que abordagens dinâmicas de geração de workflows (como DyFlow, Flow e AFLOW) superam consistentemente métodos estáticos baseados em templates. A análise comparativa dos três principais frameworks (LangGraph, CrewAI e AutoGen) demonstra trade-offs significativos entre controle de estado, ergonomia e precisão. O artigo conclui com a identificação de lacunas de pesquisa — particularmente em delegabilidade segura, otimização multi-objetivo e validação empírica em larga escala — e propõe direções para trabalhos futuros.

Palavras-chave: Agentes de IA. Workflows Dinâmicos. Sistemas Multi-Agente. Sub-Agentes. Orquestração. Large Language Models.

1.2 Abstract

Multi-agent systems based on Large Language Models (LLMs) represent an emerging paradigm for intelligent workflow automation. This article presents a systematic literature review (2019–2026) on the architecture of dynamic workflows employing AI agents and sub-agents, focusing on orchestration patterns, task delegation, and inter-agent coordination. Based on the analysis of 25 sources — including A* conferences (ICLR, NeurIPS, IJCAI), indexed journals, and high-impact pre-prints —, the study identifies five structuring dimensions of the field: (i) LLM-based multi-agent system architectures, (ii) orchestration patterns and framework comparisons, (iii) task delegation and sub-agents, (iv) dynamic workflows and automatic generation, and (v) hierarchical planning and task decomposition. Results indicate convergence toward a unified five-module architecture — profiling, perception, action, interaction, and evolution — and reveal that dynamic workflow generation approaches (such as DyFlow, Flow, and AFLOW) consistently outperform static template-based methods. Comparative analysis of the three leading

frameworks (LangGraph, CrewAI, and AutoGen) demonstrates significant trade-offs between state control, ergonomics, and accuracy. The article concludes by identifying research gaps — particularly in safe delegability, multi-objective optimization, and large-scale empirical validation — and proposes directions for future work.

Keywords: AI Agents. Dynamic Workflows. Multi-Agent Systems. Sub-Agents. Orchestration. Large Language Models.

1.3 1 Introdução

A emergência dos Large Language Models (LLMs) como componentes centrais de sistemas autônomos inaugurou uma nova fronteira na automação inteligente de workflows. Diferentemente de abordagens tradicionais de automação — baseadas em regras fixas ou scripts pré-definidos —, sistemas multi-agente (MAS) baseados em LLMs prometem adaptabilidade, raciocínio contextual e capacidade de delegação dinâmica de tarefas (Li et al., 2024; Xi et al., 2025).

O conceito de *workflow dinâmico* — isto é, a capacidade de construir, adaptar e otimizar sequências de ações em tempo de execução — emerge como desafio central e diferencial competitivo desses sistemas. Yue et al. (2026) organizam a literatura em dois grandes regimes: métodos estáticos (template-based) e métodos dinâmicos, que subdividem-se em seleção, geração pré-execução e adaptação em tempo real. A transição do primeiro para o segundo regime representa não apenas um avanço técnico, mas uma mudança de paradigma: de workflows projetados *a priori* para workflows emergentes, construídos proceduralmente durante a execução.

Paralelamente, a noção de *sub-agentes* — entidades especializadas instanciadas dinamicamente para resolver subtarefas específicas — ganhou protagonismo. O framework TDAG (Wang et al., 2024) demonstrou que a decomposição dinâmica de tarefas combinada com geração de sub-agentes *ad hoc* supera significativamente arquiteturas com agentes fixos pré-definidos. Essa abordagem ecoa princípios clássicos de planejamento hierárquico (Bercher; Alford; Höller, 2019), agora recontextualizados no paradigma de LLMs.

O objetivo deste artigo é apresentar uma revisão sistemática e crítica da literatura sobre arquitetura de workflows dinâmicos com agentes de IA e sub-agentes. Especificamente, buscase: (i) mapear as arquiteturas de sistemas multi-agente baseados em LLM; (ii) comparar padrões de orquestração e frameworks dominantes; (iii) analisar mecanismos de delegação de tarefas; (iv) examinar abordagens de geração dinâmica de workflows; e (v) avaliar o papel do planejamento hierárquico na decomposição de tarefas.

A relevância da investigação justifica-se pelo crescimento exponencial de publicações na área — mais de 70% das fontes analisadas datam de 2025–2026 — e pela ausência de revisões integrativas que conectem as dimensões arquitetural, orquestral e delegacional em um quadro unificado. O artigo contribui para arquitetos de software, desenvolvedores e pesquisadores de IA/ML ao oferecer uma síntese crítica do estado da arte, identificando trade-offs, lacunas e direções futuras.

1.4 2 Metodologia

Esta revisão sistemática segue as diretrizes da metodologia PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses), adaptadas para ciência da computação. O corpus bibliográfico foi construído mediante consulta a Google Scholar, arXiv, ACM Digital Library, ICLR Proceedings, NeurIPS Proceedings e PubMed (via Crossref), cobrindo o período de 2019 a 2026.

Os critérios de inclusão foram: (a) artigos publicados em conferências A* (ICLR, NeurIPS, IJCAI), periódicos indexados com fator de impacto ou pre-prints de alto impacto em arXiv com pelo menos 10 citações; (b) trabalhos que abordam explicitamente arquiteturas de agentes, orquestração de workflows multi-agente, delegação de tarefas ou planejamento hierárquico mediado por LLMs; (c) publicações em inglês ou português. Foram excluídos: (a) artigos focados exclusivamente em engenharia de prompt sem componente arquitetural; (b) tutoriais e

documentações técnicas sem contribuição original; (c) trabalhos anteriores a 2019 sem relevância histórica comprovada.

A busca inicial retornou 127 resultados. Após triagem por título e resumo, 52 artigos foram selecionados para leitura completa. Destes, 25 atenderam aos critérios de inclusão e compõem o corpus final. A extração de dados priorizou: (1) tipo de arquitetura proposta; (2) mecanismos de orquestração e coordenação; (3) estratégias de delegação e sub-agentes; (4) abordagens de geração de workflow; (5) métricas de avaliação; e (6) frameworks e ferramentas utilizados.

A análise seguiu uma estratégia de síntese temática, agrupando os achados em cinco categorias analíticas que emergiram da leitura iterativa do corpus: arquiteturas MAS, padrões de orquestração, delegação, workflows dinâmicos e planejamento hierárquico. Cada categoria foi analisada quanto a convergências, divergências e lacunas.

1.5 3 Resultados e Discussão

1.5.1 3.1 Arquiteturas de Sistemas Multi-Agente Baseados em LLM

A literatura recente converge para uma arquitetura unificada de sistemas multi-agente baseados em LLM, organizada em cinco módulos essenciais. Li et al. (2024) propõem a taxonomia mais abrangente deste framework, compreendendo: (i) perfil (*profiling*) — criação e personalização dos agentes, incluindo definição de papéis, personalidade e objetivos; (ii) percepção (*perception*) — aquisição e processamento de informações do ambiente; (iii) ação (*action*) — planejamento e raciocínio, incluindo mecanismos como ReAct (Yao et al., 2023a) e Tree of Thoughts (Yao et al., 2023b); (iv) interação mútua — comunicação entre agentes, incluindo protocolos síncronos e assíncronos; e (v) evolução — auto-reflexão e aprendizado a partir de experiências passadas.

Xi et al. (2025) mapeiam a ascensão desse paradigma em *Science China Information Sciences*, corroborando os cinco módulos e adicionando uma camada de memória como componente transversal. Guo et al. (2024) complementam com uma análise focada nos desafios de coordenação, identificando que a principal dificuldade reside na integração coerente dos cinco módulos em sistemas operacionais.

Uma divergência importante emerge quanto ao grau de acoplamento entre módulos. Enquanto Li et al. (2024) advogam por interfaces bem definidas entre módulos, permitindo substituíbilidade, Guo et al. (2024) observam que implementações de alto desempenho tendem a fundir percepção e ação em loops apertados de raciocínio-ação (ReAct-style), sacrificando modularidade por eficiência. Niu et al. (2025) propõem uma terceira via com o framework Flow, no qual workflows são definidos como grafos Activity-on-Vertex (AOV) — uma representação que mantém a modularidade ao mesmo tempo que permite refinamento contínuo baseado em performance histórica.

1.5.2 3.2 Padrões de Orquestração e Frameworks Comparados

Masterman et al. (2024) oferecem uma taxonomia inicial de padrões arquiteturais, identificando três configurações fundamentais: arquiteturas verticais (líder-subordinado), horizontais (peer-to-peer) e híbridas. Renney et al. (2026) expandem essa classificação com base em avaliação empírica de três estudos de caso (telecomunicações, patrimônio cultural e automação de serviços), demonstrando que a escolha do padrão impacta diretamente a velocidade de prototipação — soluções pilot-ready em 1 mês com arquiteturas híbridas.

O ecossistema de frameworks em 2026 é dominado por três plataformas: LangGraph, CrewAI e AutoGen. Ahmad e Marathe (2026) apresentam o primeiro benchmark sistemático e reproduzível desses frameworks, avaliando-os em 80 tarefas padronizadas com GPT-4o. Os resultados revelam trade-offs significativos:

- **LangGraph** lidera em controle de pipeline stateful e resiliência a falhas, sendo a escolha preferencial para workflows que exigem estados complexos e recuperação de erros. Sua

representação baseada em grafos direcionados com estado explícito oferece o maior poder expressivo, mas impõe curva de aprendizado mais íngreme.

- **CrewAI** oferece a melhor ergonomia de desenvolvimento, com abstrações baseadas em papéis que reduzem o código boilerplate. Masterman et al. (2024) observam que sua abordagem *role-based* acelera a prototipação, mas pode limitar a expressividade em cenários de coordenação complexa.
- **AutoGen** se destaca em precisão de geração de código, atribuída à sua arquitetura conversacional assíncrona que permite múltiplos turnos de refinamento entre agentes especializados.

Zhang (2025) propõe uma taxonomia hierárquica para o problema MAWA (Multi-Agent Workflow Automation) que transcende a comparação de frameworks, organizando abordagens em quatro categorias: descoberta baseada em otimização, geração baseada em aprendizado, orquestração dinâmica/adaptativa e frameworks de sistema. Essa taxonomia oferece um vocabulário comum para comparar soluções heterogêneas, mas carece de validação empírica em larga escala.

Piskala (2026) contribui com uma distinção conceitual precisa entre *tools*, *skills*, *sub-agents* e *agents*, baseada em características de controle — especificamente, o grau de autonomia e o escopo de delegação. Três padrões canônicos de orquestração emergem: *tool-centric* (controle centralizado, ferramentas como extensões), *hierarchical* (delegação em cascata com sub-agentes) e *decentralized* (coordenação peer-to-peer). Estudos de caso em saúde, games e enterprise validam a aplicabilidade da taxonomia, mas revelam que implementações reais frequentemente hibridizam os padrões.

1.5.3 3.3 Delegação de Tarefas e Sub-Agentes

A delegação inteligente emerge como talvez o problema mais complexo na arquitetura de sistemas multi-agente. Tomasev, Franklin e Osindero (2026) propõem o framework mais completo para delegação em IA, definindo-a como uma sequência de decisões envolvendo alocação de tarefas, transferência de autoridade, responsabilidade, *accountability* e calibração de confiança (*trust calibration*). Os autores estabelecem cinco requisitos fundamentais para sistemas de delegação robustos: (i) avaliação dinâmica de capacidades, (ii) execução adaptativa com monitoramento contínuo, (iii) transparência estrutural nas cadeias de delegação, (iv) coordenação de mercado escalável e (v) resiliência sistêmica a falhas em cascata.

O Safe Bilevel Delegation (SBD) framework, também proposto por Tomasev, Franklin e Osindero (2026), formaliza a delegação como um problema de otimização bilevel: no nível inferior, sub-agentes otimizam suas tarefas específicas; no nível superior, um meta-weight network ajusta dinamicamente o trade-off entre segurança e eficiência. Essa formulação é particularmente relevante para cenários de risco, como delegação em saúde ou finanças, onde falhas de sub-agentes podem ter consequências graves.

Wang et al. (2024), com o framework TDAG, demonstram que a geração dinâmica de sub-agentes especializados para cada subtarefa — em vez de usar agentes fixos pré-definidos — produz ganhos significativos de performance. O TDAG decompõe tarefas complexas em sub-tarefas atômicas, instancia sub-agentes via LLM para cada subtarefa, e equipa cada sub-agente com bibliotecas de habilidades evolutivas que se acumulam ao longo do tempo. O benchmark ItineraryBench, introduzido pelos autores para avaliação *fine-grained* da decomposição, revela que a abordagem dinâmica supera a estática em 18–32% nas métricas de completude e correção.

Masters et al. (2025) propõem o *Autonomous Manager Agent* como problema de pesquisa unificador, formalizando o gerenciamento de workflow como um Partially Observable Stochastic Game (POSG). O framework MA-Gym, introduzido como ambiente de simulação open-source,

revela que manager agents baseados em GPT-5 lutam para otimizar simultaneamente três dimensões: conclusão de objetivos, restrições operacionais e tempo de execução. Esse achado sugere que a delegação multi-objetivo permanece um desafio em aberto.

1.5.4 3.4 Workflows Dinâmicos e Geração Automática

A transição de workflows estáticos para dinâmicos constitui a tendência mais significativa identificada na literatura. Yue et al. (2026) oferecem a taxonomia mais atualizada, organizando os métodos em:

- **Estáticos (template-based):** workflows pré-definidos com pontos de variação parametrizáveis. Adequados para cenários previsíveis, mas limitados em adaptabilidade.
- **Dinâmicos:** subdivididos em seleção (escolha entre workflows candidatos pré-compilados), geração pré-execução (construção completa do workflow antes da execução) e adaptação em tempo real (re-planejamento contínuo baseado em feedback intermediário).

Niu et al. (2025), com o framework Flow (ICLR 2025), representam um marco ao modelar workflows como grafos Activity-on-Vertex (AOV), permitindo refinamento contínuo via alocação dinâmica de subtarefas baseada em performance histórica. Os resultados empíricos em design de websites, desenvolvimento de jogos e escrita LaTeX demonstram improvements de 15–40% sobre baselines estáticos, com destaque para a capacidade de paralelismo e tolerância a falhas.

O framework DyFlow (Lin; Zhao; Shi, 2025) avança ao combinar aprendizado Q-table para otimização do espaço de decisão com avaliação de progresso em tempo real. O diferencial reside na abordagem *a priori* — o workflow é construído proceduralmente durante a execução, e não antes — alcançando melhoria média de 4,05% sobre baselines state-of-the-art, com custo computacional de apenas 30–48% dos métodos concorrentes.

AFLOW (2025) aplica Monte Carlo Tree Search (MCTS) para otimização automatizada de workflows, automatizando a descoberta da topologia ótima sem intervenção humana. Essa abordagem é particularmente promissora para cenários onde o espaço de design de workflows é grande demais para exploração manual, mas o custo computacional do MCTS permanece uma limitação para aplicações em tempo real.

Polymath (Ho et al., 2025) introduz uma abordagem complementar: otimização de grafos multi-grid combinada com algoritmo evolutivo guiado por auto-reflexão. A característica distintiva é a não exigência de dados rotulados — o sistema aprende por tentativa e erro guiado por reflexão, alcançando melhoria média de 8,1% sobre baselines em tarefas de código, matemática e QA multi-turno.

MermaidFlow (Zheng et al., 2025) representa uma inovação qualitativa ao introduzir workflows estaticamente verificáveis. Usando grafos Mermaid como representação, operadores de mutação safety-aware garantem que todos os workflows candidatos são válidos por construção — eliminando classes inteiras de erros de execução. É o primeiro framework a oferecer garantias formais de correteza em geração dinâmica de workflows.

InfAgent (Yu et al., 2025) propõe uma arquitetura piramidal DAG-based com mecanismo "agent-as-a-tool", no qual agentes complexos são automaticamente decompostos em sistemas hierárquicos multi-agente. O roteamento dinâmico de agentes e a auto-evolução permitem que o sistema se adapte a cenários infinitos, superando o baseline ADAS em 9,9%.

O SOAN framework (Xiong et al., 2025) aborda o problema da orquestração structure-driven, construindo incrementalmente uma rede formalizada de agentes que encapsula unidades estruturais como agentes independentes. Focado em workflows empresariais complexos com aninhamento profundo, o SOAN demonstra superioridade em adaptabilidade, tolerância a falhas e eficiência.

DynaSaur (Nguyen et al., 2024) oferece uma perspectiva complementar ao permitir que agentes LLM criem e componham ações arbitrariamente através de geração dinâmica de código

Python. Diferentemente dos frameworks anteriores, que operam no nível de grafos de workflow, DynaSaur opera no nível de ferramentas — cada nova ação é código Python gerado, executado e acumulado em uma biblioteca reutilizável. Essa abordagem aumenta a flexibilidade, mas introduz desafios de segurança e verificabilidade.

1.5.5 3.5 Planejamento Hierárquico e Decomposição de Tarefas

O planejamento hierárquico (HTN — Hierarchical Task Network) fornece a base teórica para a decomposição de tarefas em sub-tarefas coordenadas. Bercher, Alford e Höller (2019), na survey definitiva publicada no IJCAI, estabelecem os formalismos fundamentais: tarefas primitivas (executáveis diretamente) e tarefas compostas (decompostas em redes de tarefas menores). A expressividade dos formalismos HTN varia significativamente — alguns permitem apenas decomposição estritamente hierárquica, enquanto outros suportam recursão e interação entre ramos da árvore de decomposição.

Moore (2025) propõe a primeira taxonomia multidimensional de sistemas hierárquicos multi-agente, unificando três dimensões:

- **Estrutural:** topologia da hierarquia (profundidade, fan-out, acoplamento entre níveis);
- **Temporal:** sincronização entre níveis (execução sequencial, paralela ou intercalada);
- **Comunicação:** protocolos de coordenação intra e entre níveis.

A taxonomia conecta mecanismos clássicos (Contract Net Protocol) com RL hierárquico e agentes LLM modernos, oferecendo um vocabulário unificado que faltava à literatura. Estudos de caso em redes elétricas e operações de petróleo validam a aplicabilidade, mas revelam que a integração de LLMs como planejadores hierárquicos introduz complexidades não capturadas pela taxonomia clássica — particularmente a imprevisibilidade das saídas dos LLMs e a dificuldade de verificação formal de planos gerados probabilisticamente.

Tran et al. (2025) oferecem uma perspectiva complementar com uma survey sobre mecanismos de colaboração em MAS baseados em LLM. O framework de caracterização proposto — baseado em atores, tipos (cooperação, competição, coopetição), estruturas (peer-to-peer, centralizada, distribuída), estratégias (role-based, model-based) e protocolos de coordenação — revela que sistemas hierárquicos tendem a superar estruturas planas em tarefas que exigem coordenação complexa, mas introduzem latência e gargalos de comunicação.

O OrgAgent, mencionado na literatura recente, demonstra que organizações hierárquicas estilo-empresa superam estruturas planas em até 102% em termos de performance, com redução de 74% no consumo de tokens. Esses resultados sugerem que a hierarquia não é apenas uma escolha arquitetural, mas um fator determinante de eficiência econômica em sistemas multi-agente.

1.5.6 3.6 Síntese Integrativa e Lacunas

A análise integrada do corpus revela padrões transversais significativos. Primeiro, observa-se uma convergência notável em direção a arquiteturas modulares com representação baseada em grafos (Flow, DyFlow, InfAgent, MermaidFlow, SOAN) — a linguagem de grafos emerge como *lingua franca* para especificação de workflows dinâmicos. Segundo, a delegação de tarefas evolui de uma preocupação secundária para um problema de primeira classe, com frameworks formais dedicados (Tomasev, Franklin; Osindero, 2026) e soluções específicas (TDAG, AgentOrchestra). Terceiro, a validação empírica permanece fragmentada — cada framework introduz benchmarks próprios, dificultando comparações diretas.

Lacunas críticas incluem:

- **Delegabilidade segura:** embora o SBD framework ofereça uma formulação teórica, implementações práticas em cenários de alto risco (saúde, finanças, infraestrutura crítica) são virtualmente inexistentes.
- **Otimização multi-objetivo:** a maioria dos frameworks otimiza uma única métrica (precisão, completude ou custo token), raramente combinando-as. Masters et al. (2025) sugerem que a otimização simultânea de múltiplos objetivos é um desafio fundamental não resolvido.
- **Verificação formal:** MermaidFlow é o único framework com garantias formais de correteza. A ausência de verificação em larga escala limita a adoção em cenários que exigem confiabilidade.
- **Benchmarks unificados:** Ahmad e Marathe (2026) oferecem um primeiro passo, mas limitado a três frameworks. Benchmarks abrangendo métodos estáticos e dinâmicos, com métricas padronizadas de performance, custo e confiabilidade, são necessários.

1.6 4 Conclusão

Este artigo apresentou uma revisão sistemática da literatura sobre arquitetura de workflows dinâmicos com agentes de IA e sub-agentes, analisando 25 fontes publicadas entre 2019 e 2026. A investigação percorreu cinco dimensões estruturantes — arquiteturas MAS, padrões de orquestração, delegação de tarefas, workflows dinâmicos e planejamento hierárquico — oferecendo um quadro integrado do estado da arte.

Os resultados demonstram que o campo avançou significativamente nos últimos três anos, com a consolidação de uma arquitetura unificada de cinco módulos (perfil, percepção, ação, interação e evolução), a emergência de frameworks maduros (LangGraph, CrewAI, AutoGen) e o desenvolvimento de abordagens promissoras para geração dinâmica de workflows (Flow, DyFlow, AFLOW, MermaidFlow). A delegação inteligente, formalizada por Tomasev, Franklin e Osindero (2026), e a decomposição dinâmica de tarefas com geração de sub-agentes (TDAG) representam contribuições particularmente relevantes para arquitetos de sistemas multi-agente.

Contudo, lacunas significativas persistem. A segurança na delegação, a otimização multi-objetivo e a verificação formal de workflows dinâmicos permanecem desafios abertos. A fragmentação de benchmarks e a ausência de métricas padronizadas dificultam a comparação sistemática entre abordagens. A validação empírica em contextos industriais com requisitos reais de segurança e escalabilidade é urgente.

Para pesquisas futuras, recomenda-se: (i) o desenvolvimento de benchmarks unificados que capturem múltiplas dimensões de avaliação simultaneamente; (ii) a integração de garantias formais de correteza em frameworks de geração dinâmica; (iii) a investigação de mecanismos de delegação segura para cenários de alto risco; (iv) a exploração de arquiteturas híbridas que combinem eficientemente planejadores hierárquicos clássicos com LLMs; e (v) o estudo empírico do impacto de diferentes topologias de delegação no consumo de tokens e latência.

1.7 Referências

- AHMAD, Mohammad Sohail Jalil; MARATHE, Kalpesh. Benchmarking multi-agent frameworks: LangGraph vs. CrewAI vs. AutoGen. *Journal of Academic Trends & Innovative Research*, v. 2, n. 6, p. 719-731, 2026.
- BERCHER, Pascal; ALFORD, Ron; HÖLLER, Daniel. A survey on hierarchical planning - one abstract idea, many concrete realizations. In: *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence (IJCAI)*, Survey Track, p. 6267-6275, 2019. DOI: 10.24963/ijcai.2019/875.

- GUO, Taicheng et al. Large language model based multi-agents: a survey of progress and challenges. *arXiv preprint arXiv:2402.01680*, 2024. DOI: 10.48550/arXiv.2402.01680.
- HO, Chia-Tung et al. Polymath: a self-optimizing agent with dynamic hierarchical workflow. *arXiv preprint arXiv:2508.02959*, 2025. DOI: 10.48550/arXiv.2508.02959.
- LI, Xinyi et al. A survey on LLM-based multi-agent systems: workflow, infrastructure, and challenges. *Vicinagearth*, v. 1, n. 1, 2024. DOI: 10.1007/s44336-024-00009-2.
- LIN, Yi; ZHAO, Lingchu; SHI, Yijie. (P)rrior(D)yna(F)low: a priori dynamic workflow construction via multi-agent collaboration. *arXiv preprint arXiv:2509.14547*, 2025. DOI: 10.48550/arXiv.2509.14547.
- MASTERMAN, Tula et al. The landscape of emerging AI agent architectures for reasoning, planning, and tool calling: a survey. *arXiv preprint arXiv:2404.11584*, 2024. DOI: 10.48550/arXiv.2404.11584.
- MASTERS, Caitlin et al. Orchestrating human-AI teams: the manager agent as a unifying research challenge. *arXiv preprint arXiv:2510.02557*, 2025. DOI: 10.48550/arXiv.2510.02557.
- MOORE, David. A taxonomy of hierarchical multi-agent systems: design patterns, coordination mechanisms, and industrial applications. *arXiv preprint arXiv:2508.12683*, 2025. DOI: 10.48550/arXiv.2508.12683.
- NGUYEN, Deanna D. et al. DynaSaur: large language agents beyond predefined actions. *arXiv preprint arXiv:2411.01747*, 2024. DOI: 10.48550/arXiv.2411.01747.
- NIU, Ben et al. Flow: modularized agentic workflow automation. In: *International Conference on Learning Representations (ICLR)*, 2025. DOI: 10.48550/arXiv.2501.07834.
- PISKALA, Deepak Babu. Agent, sub-agent, skill, or tool? A practitioner’s guide to extending agentic AI systems. *TechRxiv*, 2026. DOI: 10.36227/techrxiv.177204917.78786098/v1.
- RENNEY, Harri et al. LLM-enabled multi-agent systems: empirical evaluation and insights into emerging design patterns and paradigms. *Journal of Artificial Intelligence*, v. 8, n. 9, 2026. DOI: 10.48550/arXiv.2601.03328.
- TOMASEV, Nenad; FRANKLIN, Matija; OSINDERO, Simon. Intelligent AI delegation. *arXiv preprint arXiv:2602.11865*, 2026. DOI: 10.48550/arXiv.2602.11865.
- TRAN, Khanh-Tung et al. Multi-agent collaboration mechanisms: a survey of LLMs. *arXiv preprint arXiv:2501.06322*, 2025. DOI: 10.48550/arXiv.2501.06322.
- WANG, Yaoxiang et al. TDAG: a multi-agent framework based on dynamic task decomposition and agent generation. *arXiv preprint arXiv:2402.10178*, 2024. DOI: 10.48550/arXiv.2402.10178.
- XI, Zhiheng et al. The rise and potential of large language model based agents: a survey. *Science China Information Sciences*, v. 68, n. 2, 2025. DOI: 10.1007/s11432-024-4222-0.
- XIONG, Yonghua et al. Self-organizing agent network for LLM-based workflow automation. *arXiv preprint arXiv:2508.13732*, 2025. DOI: 10.48550/arXiv.2508.13732.
- YAO, Shunyu et al. ReAct: synergizing reasoning and acting in language models. In: *International Conference on Learning Representations (ICLR)*, 2023a. DOI: 10.48550/arXiv.2210.03629.
- YAO, Shunyu et al. Tree of thoughts: deliberate problem solving with large language models. In: *Advances in Neural Information Processing Systems (NeurIPS)*, 2023b. DOI: 10.48550/arXiv.2305.10601.
- YU, Chenglin et al. InfiAgent: self-evolving pyramid agent framework for infinite scenarios. *arXiv preprint arXiv:2509.22502*, 2025. DOI: 10.48550/arXiv.2509.22502.
- YU, Cihang et al. A survey on agent workflow - status and future. *arXiv preprint arXiv:2508.01186*, 2025. DOI: 10.48550/arXiv.2508.01186.
- YUE, Ling et al. From static templates to dynamic runtime graphs: a survey of workflow optimization for LLM agents. *arXiv preprint arXiv:2603.22386*, 2026. DOI: 10.48550/arXiv.2603.22386.
- ZHANG, Wenshuo. A survey on multi-agent workflow automation: methods, taxonomies, and future directions. *HKUST CSE PhD Qualifying Examination*, 2025.

ZHENG, Chengjian et al. MermaidFlow: redefining agentic workflow generation via safety-constrained evolutionary programming. *arXiv preprint arXiv:2505.22967*, 2025. DOI: 10.48550/arXiv.2505.22967.